

Глобальная картина взаимодействий

- **Объем данных и разреженность:** В логах ~8.78 млн взаимодействий, охватывающих 2 682 603 уникальных пользователей и 740 651 товаров за 47 дней ¹. Матрица user-item крайне разреженная (плотность всего $\sim 4.4 \times 10^{-6}$ ²). В среднем на пользователя приходится ~3.27 взаимодействия, а на товар ~11.85 взаимодействия ³ ⁴, однако распределения очень неравномерные (см. "head-tail").

Что значит: Данные большого масштаба при очень низкой плотности – подавляющее большинство возможных пар user-item никогда не встречаются. Пользователи совершают мало взаимодействий в среднем, а товаров очень много относительно объема событий. Такая разреженность типична для рекомендательных задач с имплицитным фидбэком, здесь добавляется еще и огромный каталог.

Вывод для RS: Модели должны быть масштабируемыми и устойчивыми к разреженности. Коллаборативные методы (CF) столкнутся с холодным стартом для множества пользователей и товаров. Необходимо использовать устойчивые к разреженности подходы: например, популярность и недавние тренды как базовые сигналы, а для персонализации – методы типа item-item (ко-визиты) или factorization, которые справляются с большими размерами. Предобработка может включать фильтрацию/клиппинг аномалий (см. ниже) и возможно семплирование для баланса head/tail.

- **Динамика по дням:** Ежедневно фиксируется порядка $1.6\text{--}2.1 \times 10^5$ взаимодействий (медиана ~189k/день) ⁵ с участием ~75–110 тыс. пользователей и ~45–57 тыс. разных товаров (после стартового дня 0) ⁶ ⁷. Активность "дышит" по дням, но без резких провалов: после пика на 1–2-й день наблюдается небольшое снижение, далее колебания в пределах $\sim \pm 15\%$.

Что значит: Аудитория и общий спрос относительно стабильны на всем периоде, нет явных провалов или экспоненциального роста/спада. Суточные колебания могут отражать будни/выходные или маркетинговые активности, но в целом объем взаимодействий ровный, что упрощает моделирование (можно считать данные стационарными в рамках окна).

Вывод для RS: Модель не нуждается в специальных корректировках под сильный сезонный тренд – можно использовать последние данные как актуальные. Однако небольшие колебания (например, рост к выходным) можно учесть через фичи дня недели или временного декея. Важнее то, что каждый день приходят новые пользователи и товары (см. далее) – это указывает на постоянный приток нового контента и аудитории, требуя от алгоритма быстрой адаптации.

- **Распределение "head-tail" по пользователям и товарам:** Распределения очень skewed (смещены в длинный хвост). 50% пользователей совершили только 1–2 взаимодействия за весь период ⁸, 90% – ≤ 7 взаимодействий. Максимум на одного пользователя – 899 действий ⁹ ¹⁰. Со стороны товаров: 50% товаров получили всего 1 взаимодействие (медиана=1) ¹¹, 90% – ≤ 8 взаимодействий, 99% – ≤ 79 . Лишь 1% товаров перевалили за 80 показов; самый популярный товар имеет 219 184 взаимодействия ¹² ¹³ (колоссальный отрыв от медианы).

Что значит: Огромное множество "одноразовых" пользователей и товаров. Аудитория распределена сравнительно равномерно – нет пользователей, доминирующих в логах (даже топ-пользователь генерирует $< 0.01\%$ событий). Зато каталог крайне неоднороден: есть небольшой "головной" набор хитов, собирающих большую часть взаимодействий, и

длинный хвост из сотен тысяч товаров, которые почти никем не просмотрены.

Вывод для RS: (а) Модель должна уделять особое внимание холодным пользователям и товарам. Половина пользователей практически не имеет истории – для них персонализация затруднена, стоит опираться на популярность или контекст. Аналогично, половина товаров не имеет достаточного сигнала – их сложно рекомендовать, не подкрепляя контентными фичами или эксплорингом. **(б)** Популярность – мощный фактор: небольшое число популярных позиций покрывает значительную долю спроса (см. покрытие ниже), поэтому для высокого recall в кандидатах обязательно должны быть самые популярные и трендовые товары. **(в)** Однако переусердствовать с популярностью опасно: легко скатиться к однообразным рекомендациям из топ-100, игнорируя длинный хвост и персонализацию. Нужен баланс – например, микс кандидатов из популярности и специфических для пользователя (через контент или ко-визы).

- **Coverage топ-K:** Каталог крайне концентрирован по популярности. **Топ-10** товаров дают $\approx 14\%$ всех взаимодействий, **топ-50** – **27.6%**, **топ-100** – **34.5%**, **топ-1 000** – $\approx 55\%$, **топ-10 000** – $\approx 71.7\%$ ¹⁴ ¹⁵. То есть $\sim 1.3\%$ самых популярных товаров покрывают $\sim 72\%$ всего спроса. В то же время **топ-10 пользователей** совокупно ответственны лишь за **0.07%** событий, топ-100 – $\sim 0.4\%$, топ-10 000 (0.37% пользователей) – $\sim 8.3\%$ событий ¹⁶ ¹⁷.

Что значит: Каталог “узкий”, аудитория “широкая”. Львиная доля активности приходится на ограниченный пул популярных товаров, а вклад даже самых активных юзеров мал в масштабах общего объема. Проще говоря, пользователи в среднем просматривают уникальные для себя товары, не повторяя за другими, тогда как многие пользователи сходятся на одних и тех же хитах.

Вывод для RS: (а) Базовый кандидат-генератор на популярных товарах даст высокий охват по пользователям (почти каждый пользователь заинтересован хотя бы в части хитов) и поймает значимую долю событий. Например, рекомендуя каждому топ-1000 товаров, теоретически можно перекрыть $\sim 55\%$ реальных интеракций – неплохой проху-recall. **(б)** Однако рекомендации только из узкого топа ограничат **coverage по каталогу** – система будет предлагать меньше 1% товаров, игнорируя 99% позиций. Это плохо для открытия нового и может привести к конкуренции пользователей за один и тот же контент. Нужно расширять охват: добавлять кандидатов из средней и хвостовой части (например, через персональные похожие товары, новинки, категории интереса пользователя). **(в)** Распределение по пользователям указывает, что **персонализация должна работать “вширь”**, а не фокусироваться на нескольких суперактивных индивидуумах. Метрики вроде hit-rate/recall не будут искажены кучкой пользователей – важно угодить как можно более широкой массе “обычных” юзеров.

- **Аномалии и клиппинг:** В данных присутствуют “сверх-активные” пользователи и товары, но их можно четко ограничить перцентилями. Например, порог **p99** для активности пользователя – **27 взаимодействий**, **p99.9** – **78** ¹⁸. Для товара **p99** = **79**, **p99.9** $\approx$ **1041** ¹⁹. Топ-20 пользователей имеют 449–899 взаимодействий ²⁰ ²¹ (возможно, боты или редкие энтузиасты), топ-20 товаров – от $\sim 39k$ до $219k$ взаимодействий ¹³ ²² (абсолютные хиты каталога).

Что значит: 0.1% пользователей и товаров существенно выбиваются за обычные масштабы. Например, топ-товар в ~ 2.8 раза популярнее, чем порог 99.9% ($219k$ vs 1041) – экстремальный outlier. Такие объекты могут исказить средние значения, повлиять на обучение (если не нормировать), и потенциально свидетельствуют об особых случаях (акции, боты, спам).

Вывод для RS: Есть смысл **ограничивать вклад** суперактивных элементов. При расчете фичей или при отрицательном семплировании можно клиппировать счетчики на разумных порогах (например, >78 действий пользователя считать как “78+” в фичах, >1000

показов товара – как “1000+”). Это предотвратит доминирование редких аномалий при обучении модели. Также, при генерации негативов можно исключить товары-лидеры, которые и так всем показываются (чтобы модель не училась тривиально предсказывать самые популярные). В продакшене стоит мониторить и отдельно обрабатывать таких outlier-пользователей (возможно, это автоматизированные аккаунты или особый сегмент) и аномально популярные товары (проверить на накрутки либо использовать их popularity-фили с осторожностью).

Активность пользователей и повторные взаимодействия

- **Активные дни и возвраты пользователей:** Пользователи в большинстве случаев эпизодическими. **50% юзеров** были активны лишь **1 день**, **90% – ≤3 дней**, **99% – ≤7 дней** на всем интервале ²³ ²⁴. Медианный пользователь совершил все свои действия в один день. Лишь единицы удерживались надолго: максимальный span активности – **47 дней**, но это исключение (топ-1 пользователь активен 43 дня из 47 ²⁵). Также 99% пользователей имеют только 1 “стрик” активности (непрерывный период), то есть не возвращались после перерыва ²⁶.

Что значит: Аудитория характеризуется огромной ротацией и низкой retention. Большинство пришли на платформу разово или на короткий период и пропали. Регулярно заходящих изо дня в день – считанные доли процента. Проще говоря, **преимущественно каждый день приходят новые люди, а старые почти не возвращаются.**

Вывод для RS: (а) Ключевая проблема – **cold start по пользователям**. К моменту рекомендации у значительной доли тестовых юзеров не будет никакой истории взаимодействий (или она минимальна). Валидация показала, что **~96.6% пар (user, item) в тесте – новые** ²⁷, то есть для ~97% рекомендованных item не было прямого взаимодействия юзера ранее. Это совпадает с тем, что большинство юзеров вообще впервые что-то взаимодействуют в тестовом окне. Следовательно, алгоритму персонализации часто нечего “персонализировать” – нужно рекомендовать что-то априорно актуальное. (б) Стратегия для таких “новичков” – опора на **глобальные сигналы**: самые популярные и трендовые товары, или контекст (например, по времени, локации, если есть) и простые демографические паттерны. Модели типа коллаборативной фильтрации по истории будут эффективны лишь на небольшом сегменте лояльных пользователей. (в) Стоит внедрить **многоуровневую систему**: сначала определять, есть ли у пользователя достаточная история. Если нет (новый или давно не заходил) – генерировать кандидатов из популярных и свежих товаров (также можно использовать контентные рекомендации, если известны предпочтения). Если история есть – подключать персональные методы (ко-визиты, факторизационные модели по схожим пользователям и т.д.). Такая гибридная схема покрывает и холодных, и теплых пользователей.

- **Интенсивность взаимодействий:** ~**53%** пользователей совершили **только 1 действие** за весь период ⁸. Многократные взаимодействия редки: только 5% пользователей сделали >11 действий. Даже среди вернувшихся, активность нерегулярна – среднее число отдельных сессий (стриков) ~1.42, 99-перцентиль = 5 стриков ²⁶. Проще говоря, повторные визиты – редкость, и даже вернувшиеся пользователи не просматривают сотни товаров.

Что значит: Поведение большинства – “зашёл, посмотрел пару товаров, ушёл”. Это похоже на типичный сценарий e-commerce: много случайных залётных посетителей или однократных покупателей. Тех, кто долго “серфит” или постоянно приходит за новыми товарами, очень мало.

Вывод для RS: Метрики вроде среднего количества взаимодействий на пользователя малопоказательны – нужно ориентироваться на медиану и понимать, что подавляющая

часть трафика – это короткие сессии новых юзеров. Рекомендер должен уметь хорошо отрабатывать **с минимальным сигналом**: показывать релевантные товары буквально на основе 1-2 просмотренных позиций (или даже без них, если это первые показы). Целесообразно внедрять **session-based рекомендации**: алгоритмы, учитывающие последние одно-два действия в текущей сессии, чтобы сразу подхватывать интерес. Например, если пользователь кликнул товар категории “смартфоны”, дальше показывать другие смартфоны (даже без долгого профиля). Также актуальны методы типа co-visitation (см. ниже), которые как раз рассчитаны на короткую сессию.

- **Повторяемость просмотров одного товара:** Доля *repeat interactions* (повторных взаимодействий того же пользователя с тем же товаром) крайне низка – всего **~4.1%** событий ²⁸ ²⁹. Иными словами, **96% взаимодействий – это пользователь впервые видит данный товар**. Если пользователь уже взаимодействовал с товаром в прошлом, шанс, что он снова это сделает, невелик. Причем множество таких повторов обусловлено многократными кликами в тот же день или последовательными днями: например, **~19% повторов – на следующий день** после первого просмотра ³⁰. Накопленная CDF повторов показывает, что большинство случается в коротком окне: ~50% всех повторных взаимодействий происходят в пределах ~2–3 дней от первого, 90% – в пределах ~10 дней.

Что значит: Пользователи почти не возвращаются к уже просмотренным товарам. Они постоянно переключаются на что-то новое. Даже если и вернулись к товару, то обычно скоро (например, на следующий день для принятия решения). Длинные паузы (недели) до повторного просмотра – редкость (единичные случаи, максимум ~40 дней разрыва ³¹).

Вывод для RS: (а) В формировании рекомендаций **нет смысла многократно показывать одному пользователю один и тот же товар** – вероятность повторного интереса мала. Лучше фокусироваться на новых релевантных позициях. Например, исключать из кандидатов товары, которые пользователь уже видел/покупал, за редкими исключениями (если товар действительно стоит повторно показать – например, брошенная корзина – это скорее отдельная бизнес-логика ремаркетинга). **(б)** Исключение: если повтор и случается, то вскоре – значит, **сигнал свежего интереса ценен**. Если пользователь кликнул товар, но не совершил целевого действия, возможно, есть небольшой шанс, что он вернется. Поэтому можно использовать short-term re-ranking: напр. в течение пары дней после просмотра товар может повышаться в персональном рейтинге (как напоминание), но позже – нет. **(в)** Для модели это означает, что признак “юзер взаимодействовал с item в прошлом” почти всегда отрицательный на тесте (слишком мало повторов). Потому при генерации кандидатов упор на new items для юзера. Но при ранжировании можно учесть время с последнего просмотра (recency) – если уж товар был недавно просмотрен, и он снова в кандидатах, это особый случай, возможно связанный с незавершенной покупкой.

- **Появление новых пользователей в тесте:** Анализ перекрытия train/test показал, что **все тестовые пользователи и товары имели историю в train** (в sample_submission не было cold-start ID) ³². Однако это артефакт предоставленного sample – в реальных данных последней недели наверняка присутствуют новые ID. Валидация по последним 7 дням подтвердила: **~30% пользователей в валид. окне – новые, которых не было раньше**, и они дали значительную долю интеракций. Доля “cold-start” пар пользователь-товар на начало валидации **~96.6%** ³³ (то есть подавляющее большинство взаимодействий в тестовом окне происходит с новыми комбинациями u-i, что включает новых юзеров тоже). **Что значит:** Даже если финальный тест формально не добавляет совершенно новых юзеров, практически каждый активный пользователь ведет себя как новый, т.к. впервые взаимодействует с данным item в прогнозируемом окне. Много пользователей могли зарегистрироваться/активироваться лишь под конец периода. Таким образом, **условно cold-start ситуация – норма для алгоритма**.

Вывод для RS: Нужно ориентироваться на схему, как будто каждый раз рекомендуем новым юзерам. Это возвращает нас к важности неперсонализированных методов (топ-популярное, тренды) и контентных рекомендаций. Персонализация сыграет роль лишь для лояльных юзеров, чья активность продолжается в тесте. Для них можно применять истории просмотров и повторные паттерны, но таких мало. Поэтому при ранжировании финального списка стоит, помимо match с профилем, учитывать общую привлекательность товаров (популярность, новизну) – чтобы и новичку было интересно. Кроме того, можно сегментировать пользователей: отдельные алгоритмы для новых vs. возвращающихся. Например, new users – выдавать микс глобально популярных и новинок, retuning users – больше weight на похожие на их историю товары.

Жизненный цикл и популярность товаров

- **“Однодневки” и краткосрочные товары: 55.5% товаров** появлялись лишь **в 1 день** ³⁴ ³⁵, а **~72% – максимум в 2 разных дня**. Иначе говоря, большинство товаров вспыхивают и исчезают сразу. Среднее число дней активности товара – всего ~3.2, при медиане = 1 день ³⁶. Средний **span** (последний день – первый день +1) ~10.8 дня, но медиана = 1 ³⁷, 90-й перцентиль = 37 дней (то есть лишь 10% живут дольше ~5 недель). Пример: более **740 тыс.** уникальных товаров за ~47 дней, но одновременно в день активны ~45–50 тыс., и каждый день добавляются тысячи новых (см. “новые товары в день” ниже).

Что значит: Каталог очень динамичен. Большинство товаров либо очень нишевые (их посмотрели пару раз и больше не возвращались к ним), либо это новинки, быстро утратившие актуальность. Лишь небольшая часть позиций “живет” долго, собирая просмотры на протяжении недель. Видно, что у 99% товаров $\text{total_interactions} \leq 79$ ³⁸, и эти 79 зачастую набраны за краткий период. Все это указывает на рынок с множеством новинок и сильным эффектом новизны: новое появляется постоянно, но лишь немногие товары закрепляют популярность.

Вывод для RS: (а) Холодный старт по товарам – постоянный режим. Каждый день появляются тысячи новых товаров (например, в день 1 было 50k новых, день 2 – еще 39k новых и т.д. ³⁹). Многие из них в первые же дни либо достигают пика, либо остаются незамеченными. Рекомендер должен быстро реагировать на новые товары: включать их в кандидаты до того, как они наберут много исторических интеракций (например, на основе контентных признаков или ранних сигналов интереса). **(б) Столь краткий жизненный цикл** означает, что **старая популярность быстро обесценивается**. Товар, бывший хитом месяца назад, через пару недель может уже не интересовать пользователей. Значит, исторические данные надо агрессивно устаревать (time decay) – в моделях учитывать больше последние дни, чем начало окна. Это справедливо и для train/val разрыва: финальная неделя содержит массу позиций, появившихся в последние 1–2 недели, поэтому популярность нужно мерить с учётом времени.

- **Пики популярности и падение:** Практически каждый товар имеет **четко выраженный пик активности**, после которого спрос падает. Для 50% товаров пик происходит в день появления (медиана “время до накопления 50% просмотров” = 0 дней ⁴⁰). Среднее “время достижения половины совокупных интеракций” ~3.7 дня ⁴¹, но это смещено редкими долгоживущими хитами; у 90% товаров половина просмотров набрана в первые 16 дней, у 99% – в первые 33 дня. **Half-life** после пика (сколько дней до падения до 50% от пикового дневного спроса) короткий: среди ~88k товаров, где это наблюдалось, медиана = **2 дня**, 90% – ≤ 10 дней ⁴². Только единицы держат интерес дольше месяца после своего пика.

Что значит: Тренды краткосрочны. Если товар “выстрелил”, то уже через пару дней его суточные просмотры обычно падают более чем вдвое от максимума. Многие получают

весь свой трафик сразу при запуске (например, распродажа новинки – пик на старте, потом спад). Есть и “сезонные” товары, чья популярность может возвращаться волнами, но подавляющая часть – одноразовые пики.

Вывод для RS: (а) Важна свежесть рекомендаций. Рекомендую товары, популярные неделю назад, можно промахнуться – их звёздный час уже прошёл. Необходимо включать в модель признак “время от пика” или просто временную декулаю популярности. Свежие тренды должны получать повышенный ранг. **(б)** Для candidate generation полезно иметь механизм **“Trending now”**: например, отслеживать взлеты просмотров за последние сутки/часы и в реальном времени продвигать такие товары. Это позволит не упустить краткие, но значимые всплески спроса. **(в)** Быстрый half-life также подразумевает, что **delay в обучении модели критичен**: если модель обучена на данных месячной давности, она рекомендует то, что популярно уже не будет. Нужно либо часто переобучивать алгоритмы, либо использовать онлайн-лёрнинг/апдейты для item-фичей (например, обновлять популярность товаров ежедневно).

- **Стабильность популярности и “вечнозеленые” товары:** Несмотря на сильный тренд новизны, есть небольшой пласт товаров с долгой жизнью. ~1% товаров активны ≥ 30 дней, они набирают сотни и тысячи взаимодействий постепенно. Метрика Gini по распределению спроса по дням показывает, что у 5-10% товаров спрос распределен более-менее равномерно (например, $Gini < \sim 0.5$ у ~10% позиций ⁴³, что значит ни один день не доминирует). Это могут быть **хиты каталога** или постоянные бестселлеры. Например, топ-1 товар имел 219k взаимодействий и присутствовал все 47 дней, а его наибольший день дал ~13k – то есть ~6% от общего (довольно распределенно). В топ-10 товаров заметны разные паттерны: некоторые (ID 198, 56703) собирают огромные объемы и, вероятно, присутствовали почти каждый день; другие могли вспыхнуть позже. Коэффициент пересечения топ-100 товаров между соседними днями колеблется: иногда ~0.6–0.66 (довольно стабильный топ от дня к дню), иногда падает до ~0.3 (значительная ротация хитового списка) ⁴⁴ ⁴⁵. В среднем дневной топ меняется примерно наполовину каждый день.

Что значит: Есть **ядро популярных товаров**, которые держатся в топе постоянно или возвращаются часто (вероятно, базовый ассортимент или товары, генерирующие постоянный интерес). И одновременно – сильная текучка трендов на периферии топа. Например, от вчерашней сотни самых популярных сегодня в списке только ~30–60 тех же позиций, остальные – новые взлетевшие или вернувшиеся товары ⁴⁵.

Вывод для RS: (а) Следует различать **«глобально популярные»** товары (постоянные хиты, которые всегда уместны) и **«всплесковые тренды»**. Первая категория хороша как стабильные кандидаты (они покрывают базовые потребности – их многие смотрят всегда). Вторая категория важна для актуальности и новизны – их нельзя упустить, чтобы не казаться устаревшим. Кандидат-генератор должен включать и тех и других. Например, можно формировать два списка: топ-N за весь период (бестселлеры) и топ-N за последние X дней (тренды), и объединять. **(б)** При ранжировании можно вводить фичи, которые повышают новые тренды, но также не забывают про релевантность пользователя. Например, даже если пользователь профильный, ему можно подмешать 1–2 товара из глобального топа – вероятность интереса высока. **(в)** Высокая сменяемость топа говорит о том, что модели, основанные чисто на обучении на train (первых ~40 дней), могут недоучитывать новую популярность валид. периода. Нужно внедрять **time-split validation** и проверять, что алгоритм не переупор делает на устаревшие хиты.

- **Новизна vs. повторяемость товаров:** Каждый день существенная часть взаимодействий приходится на товары, которых раньше не было в логе. В первые дни приток новых товаров огромен (напр. день 1: ~50k новых товаров, что ~93% от уникальных в тот день

³⁹; далее по ~17–25k новых ежедневно). К концу периода суммарно ~740k товаров, из них ~86k появились только в последней неделе (поскольку в train окне 0–39 было ~653k товаров ⁴⁶). Однако доля интеракций с *совсем новыми* товарами в день постепенно снижается: с ~14% в начале до ~9.5% на день 9 ⁴⁷ и, вероятно, дальше падает (каталог наполняется, новые уже меньше захватывают трафик). Это значит, что новые товары не сразу получают много внимания – сначала львиная доля просмотров у уже известных позиций. Но почти все товары в итоге недолговечны, как показано выше.

Что значит: Пользовательский интерес смещен в сторону недавно появившихся товаров, но не исключительно – “старые” хиты тоже собирают свой трафик. Новые товары получают в сумме меньшую долю взаимодействий, чем старые, но все равно ощутимо (10–15% ежедневно).

Вывод для RS: (а) **Новые товары нельзя игнорировать** – каждый день ~1/10 взаимодействий связан с ними, и это валидационные (то есть будущие) события. Если рекомендационная система вовсе не предлагает новинки (ориентируясь только на исторически популярное), она пропустит этот пласт. Нужно иметь механизм включения новых товаров: например, рекомендации “новые поступления” общего плана или персонализированные новинки по категориям интересов пользователя. (б) Новинкам часто не хватает данных для классического CF, поэтому выручит **контент-ориентированность**: если знаем атрибуты товара, можно рекомендовать новинку, похожую на популярный старый товар, даже без исторических кликов. Или использовать информацию о ранних кликах: если новинку уже начали просматривать десятки пользователей с определенной сегментной принадлежностью, можно показать ее схожим пользователям. (в) При ранжировании стоит учитывать фичу “товар новее X дней” – возможно, при прочих равных новому товару можно дать небольшой буст, особенно если у пользователя мало других релевантных кандидатов.

Граф совместных просмотров (co-visitation) и кандидаты на его основе

- **Связи товаров через пользователей:** На training-интервале построен граф item-item на основе **совместных просмотров** (co-visits) в пределах одной “корзины” пользователя (здесь корзина ~ уникальный user×day). После фильтрации редких связей (пары с <2 совместными событиями) получилось ~**251 812** уникальных пар товаров ⁴⁸. Для сравнения, максимально возможное число пар $\sim 740k^2/2$, то есть граф крайне разрежен, но тем не менее четверть миллиона связей – богатый сигнал о товарных ассоциациях. В расчетах использован decay по времени ($\lambda=0.05$) – более свежие совместные события получили больший вес. Также вычислены метрики близости (cosine, lift и др.) и отранжированы соседи для каждого товара (хранилось топ-100 соседей).

Что значит: Граф показывает, какие товары склонны просматриваться одними и теми же пользователями. По сути, это имплицитные связи типа “люди, смотревшие A, также смотрят B”. 251k пар – значит, не все товары имеют соседей (многие слишком редкие), но популярные товары обросли десятками-сотнями связей.

Вывод для RS: **Co-visitation – ключевой метод генерации кандидатов** для персональных рекомендаций без тяжелого обучения. Он **масштабируется**: популярным товарам заранее известны “смежные” рекомендации, и во время инференса достаточно взять товары из истории пользователя и объединить их соседей. Такой item-item подход особенно ценен, когда профили короткие: даже 1 просмотренный товар сразу дает кандидатов (его соседей). Кроме того, он хорошо ловит тематические связи и дополняет чисто популярностные рекомендации. **Пример:** если юзер посмотрел товар X, а X связан с Y и Z, то Y, Z могут быть намного релевантнее ему, чем топ-популярные в целом (особенно

если интерес нишевый). **Важно:** граф строился по данным без ликов (train), но учитывая decays – то есть релевантен ближайшим дням. Это соответствует тому, что вкусы пользователей с течением времени смещаются – свежие связи приоритетны.

- **Прoxy-оценка качества co-vis кандидатов:** На валидации (последние 7 дней) для пользователей с историей проверили, сколько реальных просмотров покрывает метод co-vis. В эксперименте брали последние 5 просмотренных товаров пользователя, находили по графу топ соседей и формировали до **M=200 кандидатов**. Получилось покрыть ~**20.6%** валидных пар user-item (proxy Recall@200 = 0.2063) ⁴⁹ ⁵⁰. Однако это по **тем пользователям, у кого вообще были просмотры в train** (таких оказалось ~3978 из выборки ~10000 юзеров ⁵¹). Среди их истинных ~10567 взаимодействий в валид. окне ~21% были пойманы в кандидаты. Сами кандидаты образно расширяли по 5 recent товарам соседи, чаще всего добавляя очевидные вещи: похожие категории, бренды и т.п.

Что значит: Метод item-item смог заранее предсказать около пятой части реальных переходов пользователей на новые товары. Остальные ~80% остались за бортом, что ожидаемо – ведь многие валидные действия либо принадлежат cold-user (нет истории – нечего рекомендовать), либо это новые для всех товары, у которых не было граф-связей. Тем не менее, 20% recall на персональном уровне – очень неплохо для кандидатов (учитывая, что 0% для cold-users и их было большинство). Это означает, что **для пользователей с историей co-vis часто предлагает действительно то, что они потом посмотрели.**

Вывод для RS: (а) Co-vis кандидаты должны быть частью пайплайна. Они обеспечивают персонализацию для активных юзеров и расширяют охват рекомендаций за счет товарных ассоциаций. Особенно эффективны они в сочетании с короткой историей/сессией: user кликнул товар X – алгоритм сразу подставит десяток “похожих” или комплементарных к X. **(б)** Стоит комбинировать co-vis с популярностными: помним, ~97% тестовых событий – новые пары, где co-vis ничего не даст (нет истории). Для этих случаев популярные товары – спасательный круг (они покрывали ~25% валидных интеракций на уровне топ-100 ⁵²). Поэтому общий кандидат-генератор будет гибридным: популярные N позиций (для всех, чтобы не пропустить cold-users) + персональные N позиций из co-vis (для тех, у кого есть из чего генерировать). **(в)** Также, co-vis можно улучшать: применять **time-decay λ** тонкой настройки (EDA показала, $\lambda=0.08-0.12$ дает лучший coverage на валид ⁵³), фильтровать близость по lift (чтоб популярные не связывались по тривиальному совпадению), и увеличивать **K_recent** – брать больше недавних просмотренных товаров юзера. Последнее повысит recall: EDA пыталась проверить K=1,3,5 и M=50..500 (чувствительность), ожидаемо, с K=5 recall выше, чем с K=1, а с M=500 выше, чем с 200 (no diminishing returns). Например, при M=100 recall был чуть ниже ~0.206, а при M=500 мог бы дотянуться до ~0.24 (оценочно) – то есть на каждый дополнительный кандидат отдача падает. Это указывает, что **200 кандидатов на юзера – уже неплохо**, дальше выигрыш меньше. Можно выбрать M~200–300 для баланса качества и скорости.

- **Связность графа и покрытие каталога:** Co-vis связи охватывают **653 889** товаров из train ⁵⁴ ⁴⁶. То есть ~88% всех товарных ID имели хоть какие-то совместные показы. Оставшиеся ~12% товаров вообще ни разу не “сопутствовали” другим – в основном это те самые однодневки/уникальные. На валид. неделе, правда, появились новые товары вне этого графа (те ~86k new), для них связей не будет. Таким образом, часть каталога недостижима через co-vis (придется полагаться на популярность или иную логику). Кроме того, граф завязан на поведение пользователей: если какие-то тематические группы товаров никогда не смотрят в одной сессии, алгоритм их не свяжет.

Что значит: Co-visitation вносит определенное смещение: он будет рекомендовать товары, **похожие на уже популярные**. Редкие/новые товары без связей не появятся среди

кандидатов, даже если по каким-то признакам они могли бы заинтересовать пользователя.

Вывод для RS: Нужно дополнять co-vis другим подходом, чтобы **не потерять новизну и разнообразие**. В систему кандидатов можно добавить: популярные новинки (без истории), персонализацию через content (если известно, что user любит определенную категорию, добавить из нее товары, даже если они не связаны графом). Также полезно контролировать разнообразие: co-vis может предлагать много очень схожих позиций (например, к просмотренному смартфону – еще 50 смартфонов той же модели разного цвета). На этапе ранжирования стоит добавить анти-коллаборативные фишки (например, *категорийное разнообразие* или штраф за однородность листа). В целом, **граф – сильный сигнал “что похоже на X”**, но его надо уравновесить сигналом “что вообще популярно/ново” и “что дополняет профиль но не является копией уже увиденного”.

- **Практическая реализация:** Кандидаты от co-vis можно готовить офлайн (предвычислить соседей для популярных товаров) или динамически (считать в память при необходимости для товара вне топа). EDA показала, что даже с хранением по 100 соседей на товар $\text{recall}@200 \sim 20\%$ – значит, берутся соседи из нескольких seed-товаров. **Важный параметр – K_{recent} (сколько последних действий юзера берем как “seed”)**. Сессии короткие, но брать 1 товар мало: лучше 3–5 последних. Это покрывает разные интересы, если они у юзера были. Однако слишком большой K (всю историю) может добавить шум из старых интересов. Оптимум по EDA $\sim 3\text{--}5$. Также **$M_{\text{candidates}}$** : 200 на пользователя хватит, чтобы покрыть основной интерес (дальше recall растет не сильно). Это тоже удобно – не перегружать ранжирование тысячами кандидатов.

Дрейф популярности во времени

- **Смещение популярности от train к test:** Сравнение рейтинга товаров за первые 40 дней vs. в последнюю неделю показало **Spearman корреляцию ~ 0.61** ⁵⁵. Это умеренная связь: далеко не все топовые в train остались топовыми в val. Например, пересечение списков: из топ-20 train только $\sim 38\%$ ($\text{Jaccard}=0.379$) остались в топ-20 val; для топ-100 – $\sim 23\%$ ⁵⁶. Значит, $\sim 60\text{--}77\%$ популярных ранее товаров уступили место другим к концу периода. Этот сдвиг обусловлен как появлением новых хитов, так и устареванием части старых (дрейф интересов).

Что значит: Популярность – не статична во времени. Нельзя полагаться на долгоиграющий “глобальный топ” – его состав заметно обновляется за недели. Валидация подтвердила: многие хиты train потеряли позиции, и появились новые популярные товары, которых не было в train-топе.

Вывод для RS: (а) Надо использовать **time-aware модели или фишки трендов**. Например, считать популярность с экспоненциальным затуханием: последние дни весят больше. Или обучать модель на data split, близком по времени к тесту. **(б)** В продуктиве – регулярно обновлять популярные списки (ежедневно или чаще). **(в)** Рекомендации, основанные на устаревших данных, рискуют быть нерелевантными: например, показывать товары, ажиотаж вокруг которых уже прошел. Поэтому pipeline кандидатов должен быть адаптивным: модуль популярности – свежий, модуль co-vis – тоже учитывающий новые связи по мере поступления данных.

- **Эффект учета времени (decay):** EDA провела эксперимент: взвесила популярность товаров с экспоненциальным затуханием и посмотрела, как это влияет на **coverage@K** на валид. Лямбда 0.08–0.12 (довольно быстрый decay $\sim$ ориентировочно полураспад 8–12 дней) дала лучший результат. Например, **coverage@100** (процент валидных интеракций, покрытых топ-100 самых популярных товаров) вырос с ~ 0.250 (без decay) до **0.278** при $\lambda=0.08$ ⁵⁷. Рост ~ 2.8 процентных пункта означает, что учет давности позволил топ-100

лучше соответствовать реально просмотренным товарам. Похожая картина на $K=50, 200$ – везде decay улучшал покрытие ⁵⁸.

Что значит: Свежесть предпочтений пользователей повышает точность рекомендаций. Товары, которые популярны ближе к моменту рекомендации, с большей вероятностью окажутся востребованы, чем равнопоставленные по глобальному счету, но устаревшие. Конкретно, валидация показала, что топ-N по “свежей популярности” лучше покрывает фактические нужды, чем топ-N по суммарной популярности.

Вывод для RS: (а) Обязательно внедрять time-decay в популярных моделях. Например, для ежедневного обновления рейтинга можно считать метрику популярности с весом $e^{-\lambda age}$ ($\lambda \sim 0.1$ по найденному диапазону). Это позволит автоматически продвигать недавние хиты и “охлаждать” старые. **(б)** На этапе ранжирования тоже полезно иметь фичу “количество взаимодействий за последние X дней” или “день последнего взаимодействия” – модель будет учиться отдавать приоритет актуальным товарам. **(в)*** Можно рассматривать гибриды “сейчас популярное” + “популярное за все время” для разных целей: первое – для короткосрочного отклика, второе – чтобы не забыть про хиты, которые стабильно нравятся (но их и decay не сильно обесценит, если они правда стабильно просматриваются).

- **Proxy-Recall популярных кандидатов:** Как упомянуто, топ-100 самых популярных товаров (с decay) покрывали ~27.8% всех интеракций валид. окна ⁵². Если увеличить до топ-200, покрытие ~33% ⁵⁸. То есть, рекомендуя всем пользователям одинаковый список из 200 популярных позиций, теоретически можно было бы угадать ~1/3 реальных просмотров (потому что одна из позиций списка окажется тем самым товаром, который юзер в итоге посмотрел). Это “потолок” для неперсонализированной стратегии. Co-vis (персонализированная стратегия) на своем ограниченном множестве пользователей дала ~20% recall@200. Если объединить эти подходы: например, популярностью покрывать cold-users, а co-vis warm-users, можно суммарно приблизиться к более высоким метрикам.

Что значит: Популярность – очень сильный сигнал в этой задаче, даже сильнее, чем обычный для рекомендательных систем. Что логично: при такой слабой персональной истории и доминирующем head-каталоге, советуя всем популярное, мы неплохо угадываем.

Вывод для RS: (а) Нужно эксплуатировать популярность в полной мере, но **в связке с персонализацией**. Просто выдавать всем одно и то же – недостаточно (~67% действий останется непокрыто, и метрика HR@20 будет ~0.278). Персонализация (ко-визы, факторные модели) способна дополнительно поднять recall, выдавая релевантное из остального 67%. **(б)** При финальном ранжировании не стоит бояться включать популярность как фичу: модель сама поймет, когда нужно рекомендовать хит (для широкого пользователя или cold-start), а когда – нишевой товар (если видит в профиле интересы). **(в)** Также, популярность важна для **ранней фильтрации кандидатов**: например, можно обрезать слишком не популярные товары из списка соседей co-vis. Это повысит точность – маловероятно, что товар без просмотров вдруг потребуете рекомендовать (разве что он новый и контентно релевантен, но это отдельный случай).

- **Качество EDA и пробелы:** Проведенное EDA детально осветило критически важные аспекты данных для построения RS. **Хорошо раскрыто:** общий масштаб и разреженность, распределения активности, присутствие длинного хвоста, аномалии и предложения по клиппингу, динамика по дням (новые пользователи/товары каждый день, кумулятивный рост), повторяемость действий (полный анализ повторов, гар’ов, доля новых пар), привычки пользователей (стрики, возвращаемость), **жизненный цикл товаров** (первые/последние появления, span, peak, half-life, Gini, turnover топа). Кроме того, EDA сделала практический шаг – прикинула recall для простых методов (популярность, co-vis), оценив

их потенциал и чувствительность к параметрам. Это очень ценно для разработки стратегии рекомендаций: мы заранее знаем, какого порядка recall ждать от базовых подходов и где узкие места (например, co-vis не поможет новым юзерам, популярность промахнется по pop-rorular интересам).

Что можно добавить: Возможно, стоило бы углубиться в **сессионные паттерны** (например, размер среднего “корзины” – сколько товаров смотрит юзер за день; это влияет на параметр K_{recent} для co-vis). Также **анализ по сегментам**: отличаются ли распределения для новых пользователей vs. постоянных? для новых товаров vs. старых? Это помогло бы, например, понять, есть ли узкая группа “пауэр-юзеров”, на которых можно обучить отдельную модель. Полезно было бы взглянуть на **категорийную разбивку** (если есть категории товаров) – вдруг некоторые категории более long-life или чаще совместно просматриваются. Но это уже детали. В целом, EDA покрывает практически все, что нужно: от общих статистик до конкретных инсайтов для алгоритмов.

Вывод: Текущая EDA дает прочную основу для проектирования рекомендационной системы. Мы узнали, что:

- **Данные очень разреженные и “одноразовые”**, персонализация затруднена без дополнительных мер.
- **Популярность и свежесть – король**: их нужно учитывать на каждом этапе (и в генерации, и в ранжировании).
- **Co-visitation и схожие товары**: эффективный механизм конкретизации рекомендаций, особенно в короткой сессии.
- **Холодный старт – массовое явление**: упор на гибридные подходы (популярность + контент) для новых юзеров/товаров.
- **Временная динамика**: модели должны быстро учиться изменениям (онлайн-обновления, decay) из-за скоротечности трендов.

Все эти выводы уже сейчас можно транслировать в дизайн системы рекомендаций: например, многоступенчатый конвейер кандидатов (топ-популярные + co-vis + возможно модель MF для активных юзеров), использование time-decay счетчиков, агрессивное исключение просмотренных позиций, фокус на первые несколько действий пользователя (session-based logic). Благодаря EDA стратегия будет основана на конкретных цифрах и фактах, как и подобает подходу грандмастера RecSys.

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29
30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 53 54 57 58

EDA_1760646806.pdf

file:///file_00000000cc2461f8933d357c725779e7

52 55 56 EDA_1760646806 (1).pdf

file:///file_00000000e1fc61f7b571aa588e4901e9